Entregable 1: Definición del Problema

1. Descripción de los datos originales y selección de variables

Para este proyecto trabajamos con cuatro bases de datos públicas oficiales. Cada una aporta una dimensión distinta del problema: la demanda de estudiantes, la oferta física de colegios, la capacidad económica de las familias y la situación laboral del entorno.

A continuación se detalla qué contiene cada base, cuáles son todas las variables disponibles en el archivo original y cuáles se han seleccionado específicamente para el estudio justificando el motivo de la elección.

Base 1: Alumnado matriculado en enseñanzas de régimen general - `todas_02.csv`

- **Origen:** Ministerio de Educación, Formación Profesional y Deportes (MEFPD) — Portal EDUCAbaSe (Curso 2024–2025).
- **De qué trata y qué representa:** Censo oficial del alumnado escolarizado en enseñanzas de régimen general en España. Muestra cuántos alumnos cursan cada etapa educativa, clasificándolos por titularidad del centro, nivel de urbanización y provincia.
- **Volumen:** Contiene **13.608 filas y 5 columnas**, recogiendo más de 8,3 millones de matrículas en toda España. No presenta valores nulos en ninguna celda.
- **Criterio de selección:** Esta base contiene 5 variables en total y se han decidido conservar y utilizar las 5, ya que todas son esenciales para segmentar el territorio y calcular la demanda escolar.

Variable en el archivo original	¿Seleccionada?	Tipo de dato	Justificación analítica
`Comunidad autónoma/provincia`	**SÍ**	Categórico	Clave territorial para enlazar con las demás bases de datos.
`Enseñanza`	**SÍ**	Categórico	Permite aislar el alumnado en `CF Grado Básico` y en `Bachillerato` para construir la variable objetivo.
`Titularidad/financiación del centro`	**SÍ**	Categórico	Permite filtrar por `TODOS LOS CENTROS` o comparar centros públicos frente a privados/concertados.
`Grado de urbanización`	**SÍ**	Categórico	Clasificación Eurostat que permite medir la dispersión rural (`Áreas escasamente pobladas`).
`Total`	**SÍ**	Numérico	Número de alumnos matriculados en cada combinación de las dimensiones anteriores.

Base 2: Censo estatal de centros docentes - `listado_centros.xls`

- **Origen:** Registro Estatal de Centros Docentes no Universitarios (RCE) del MEFPD.
- **De qué trata y qué representa:** Inventario físico de toda la red escolar activa del país. No recoge alumnos, sino los centros existentes como unidad física de oferta educativa.
- **Volumen:** Contiene **34.843 filas y 10 columnas**.
- **Criterio de selección:** El archivo original contiene 10 columnas, pero para el análisis a escala provincial se han seleccionado **3 variables clave** (`PROVINCIA` , `NATURALEZA` y `CÓDIGO`), descartando las 7 restantes por ser meramente accesorias (nombres comerciales o datos de contacto administrativo).

Variable en el archivo original	¿Seleccionada?	Tipo de dato	Motivo de inclusión o descarte
`PROVINCIA`	**SÍ**	Categórico	Clave geográfica para enlazar la oferta con el resto de bases.
`NATURALEZA`	**SÍ**	Categórico	Identifica si el centro es `Centro público`, `Centro privado` o `Centro concertado` para calcular el porcentaje de concertada.
`CÓDIGO`	**SÍ**	Categórico	Identificador único del centro educativo; se emplea como contador para calcular el volumen total de colegios.
`COMUNIDAD AUTÓNOMA`	**NO**	Categórico	*Descartada:* Es redundante frente a `PROVINCIA` y tiene un nivel de agregación demasiado amplio.
`LOCALIDAD`	**NO**	Categórico	*Descartada:* Nivel municipal que no es homogéneo con el resto de fuentes provinciales.
`DENOMINACIÓN GENÉRICA`	**NO**	Categórico	*Descartada:* Aunque indica el tipo de centro (IES, CEIP), no clasifica la titularidad legal como `NATURALEZA`.
`DENOMINACIÓN ESPECÍFICA`	**NO**	Categórico	*Descartada:* Nombre propio del centro (ej. "Joaquín Tena"), irrelevante a nivel estadístico.
`DOMICILIO`	**NO**	Categórico	*Descartada:* Dirección postal sin valor para el cálculo provincial agregado.
`CÓD POSTAL`	**NO**	Numérico	*Descartada:* Granularidad submunicipal; queda reservada para futuros análisis espaciales con SIG.
`TELÉFONO`	**NO**	Categórico	*Descartada:* Dato administrativo de contacto sin utilidad analítica.

Base 3: Renta media provincial y autonómica - `53689.csv`

- **Origen:** Instituto Nacional de Estadística (INE) — *Atlas de Distribución de Renta de los Hogares (ADRH)*.
- **De qué trata y qué representa:** Ingresos económicos reales de los hogares a nivel territorial.
- **Volumen:** Contiene **4.920 filas y 7 columnas**.
- **Criterio de selección:** La tabla original cuenta con 7 variables. Se han seleccionado **4 variables** para aislar estrictamente la serie más reciente a nivel provincial, descartando las 3 variables de niveles territoriales no coincidentes.

Variable en el archivo original	¿Seleccionada?	Tipo de dato	Motivo de inclusión o descarte
`Provincias`	**SÍ**	Categórico	Clave territorial para enlazar con las demás bases.
`Indicadores de renta media`	**SÍ**	Categórico	Permite filtrar y seleccionar específicamente la métrica `Renta neta media por persona`.
`Periodo`	**SÍ**	Numérico	Año de registro; se utiliza para filtrar el último periodo consolidado disponible.
`Total`	**SÍ**	Numérico	Valor numérico de la renta media en euros por persona.
`Total Nacional`	**NO**	Categórico	*Descartada:* Agregado estatal que duplica registros provinciales y genera valores nulos.
`Comunidades y Ciudades Autónomas`	**NO**	Categórico	*Descartada:* Agregado regional que enmascara las diferencias intrarregionales entre provincias.
`Islas`	**NO**	Categórico	*Descartada:* Ámbito insular no homogéneo con el nivel provincial peninsular y balear.

Base 4: Paro registrado por sexo y grupos de edad - `parosexoedadprov.xls`

- **Origen:** Servicio Público de Empleo Estatal (SEPE) — Ministerio de Trabajo y Economía Social.
- **De qué trata y qué representa:** Registro del desempleo mensual desglosado por tramos de edad y sexo a escala provincial. Representa la tensión del mercado laboral y las dificultades de inserción de los jóvenes.
- **Volumen:** Contiene **64 filas estructuradas y 13 campos** tras limpiar las filas de cabecera institucional.
- **Criterio de selección:** El fichero original desglosa el paro en 13 columnas. Se han seleccionado **4 columnas** (`PROVINCIA` , `TOTAL EDAD` y los dos tramos de paro juvenil de menores de 25 años por sexo) y se han descartado los tramos de edad adulta de mayores de 25 años por no influir directamente en la decisión escolar inmediata de la adolescencia.

Variable en el archivo original	¿Seleccionada?	Tipo de dato	Motivo de inclusión o descarte
`Unnamed: 1` (`PROVINCIA`)	**SÍ**	Categórico	Clave provincial de enlace con las demás fuentes.
`TOTAL EDAD`	**SÍ**	Numérico	Volumen total de desempleados en la provincia; actúa como denominador.
`MENORES DE 25 AÑOS (Hombres)`	**SÍ**	Numérico	Paro juvenil masculino; forma el numerador de la tasa.
`MENORES DE 25 AÑOS (Mujeres)`	**SÍ**	Numérico	Paro juvenil femenino; forma el numerador de la tasa.
`TOTAL EDAD (Hombres)`	**NO**	Numérico	*Descartada:* Ya se incluye el total consolidado de la provincia.
`TOTAL EDAD (Mujeres)`	**NO**	Numérico	*Descartada:* Ya se incluye el total consolidado de la provincia.
`DE 25 A 29 AÑOS` (Hombres / Mujeres)	**NO**	Numérico	*Descartadas:* Población que ya ha superado con creces la etapa de educación secundaria.
`DE 30 A 44 AÑOS` (Hombres / Mujeres)	**NO**	Numérico	*Descartadas:* Adultos en plena vida laboral; ajenos a la elección entre FP Básica y Bachillerato.
`MAYORES DE 45 AÑOS` (Hombres / Mujeres)	**NO**	Numérico	*Descartadas:* Tramo de desempleo de larga duración que no afecta a la elección formativa temprana.

2. Antecedentes y contexto del problema

- **Qué se ha hecho previamente:**
  Estudios periódicos como los informes PISA de la OCDE y las estadísticas del Ministerio de Educación constatan que el entorno socioeconómico familiar influye de forma directa en el rendimiento y en la repetición de curso. En el ámbito nacional, informes de centros de análisis ,como *EsadeEcPol*, Fundación BBVA / IVIE, Save the Children, investigan la segregación escolar analizando cómo se distribuyen los estudiantes vulnerables entre la

red pública y la concertada, señalando el auge que está viviendo la Formación Profesional frente a las vías universitarias.

- **Qué intentan resolver esos trabajos:**
  Buscan entender por qué persisten las diferencias de rendimiento educativo según el hogar de origen y si la escuela logra mitigar esas desigualdades o simplemente las reproduce.
- **Para qué nos sirve a nosotros:**
  Nos ayuda a definir nuestra variable principal: el **ratio entre alumnos de Formación Profesional Básica y alumnos de Bachillerato**. Este ratio no mide si un alumno abandona el Bachillerato una vez dentro, sino la división previa que ocurre al final de la secundaria, qué proporción de estudiantes es canalizada antes de los 16 años hacia un ciclo básico para no salir del sistema sin titulación, frente a los que continúan la vía académica ordinaria. Además, los estudios previos suelen quedarse en la comparación por comunidades autónomas, pasando por alto las diferencias internas que hay de una provincia a otra.

---

3. Planteamiento de la hipótesis y de los objetivos a perseguir

- **¿Qué problema pretendo resolver?**
  Queremos comprobar si la decisión de cursar Formación Profesional Básica frente a Bachillerato responde únicamente a una vocación personal del alumno o si está condicionada por el nivel de ingresos de su provincia y por la falta de plazas concertadas en su entorno físico.

- **Hipótesis de partida:**
  «El nivel de renta de los hogares y la disponibilidad de centros concertados en una provincia influyen de forma directa en la proporción de alumnos que entran a Formación Profesional Básica respecto a los que cursan Bachillerato. Prevemos que en aquellas provincias con menor renta media y una red concertada reducida, la ratio de derivación hacia la FP Básica será sensiblemente mayor a la media nacional.»

- **¿Cuál es su componente de inteligencia?**
  A partir del vector de datos provincial ,como renta media, paro juvenil, cuota de centros concertados y grado de urbanización, el proyecto desarrollará:

  1. **Modelos predictivos no lineales** para predecir de forma continua la ratio de FP Básica sobre Bachillerato y localizar si existen umbrales de ingresos a partir de los

cuales la canalización se frena o se dispara.

2. **Modelos de segmentación no supervisada** para clasificar las provincias en grupos con patrones homogéneos de vulnerabilidad o resiliencia educativa.
3. **Técnicas de interpretabilidad** para identificar qué variable concreta ,si los ingresos, la falta de colegios o el desempleo, tiene mayor peso en el resultado de cada territorio.

- **¿Qué me diferencia de un problema descriptivo/estadístico o de mera visualización?**
  Un enfoque descriptivo se limita a calcular medias o dibujar gráficos de barras, asumiendo relaciones lineales simples que no capturan la complejidad real.

  Sin embargo, el enfoque con Machine Learrning modela interacciones entre varias variables a la vez y comportamientos no lineales. Esto permite predecir el impacto de cambios en el entorno socioeconómico sobre la demanda escolar y clasificar provincias por perfiles de riesgo para orientar políticas públicas de apoyo educativo.

---

4. Posibilidades de enriquecimiento de los datos

Para no analizar la educación de forma aislada, la tabla principal del Ministerio se enriquece conectándola con las otras tres fuentes públicas a través del identificador común de **Provincia**:

1. **Datos de infraestructura física (RCE / MEFPD):**
   Permite calcular el peso real de la red concertada , `Pct_Concertado` , sobre el total de centros de la provincia para ver si la falta de oferta diversificada empuja al alumnado hacia la pública.
2. **Datos económicos de renta (INE / Atlas de Renta):**
   Aporta la renta neta media por persona y hogar, permitiendo comprobar el efecto directo del poder adquisitivo familiar en la trayectoria académica de los hijos.
3. **Datos de empleo (SEPE):**
   Permite calcular la tasa de desempleo juvenil de menores de 25 años sobre el total de desempleados para evaluar la presión del mercado laboral en la zona.
4. **Otras fuentes públicas que podrían incorporarse más adelante:**
   - **Censo de Población y Viviendas del INE:** Para incluir el nivel de estudios de la población adulta como indicador del capital educativo familiar.
   - **Cartociudad / Instituto Geográfico Nacional (IGN):** Para medir distancias medias y tiempos de desplazamiento desde municipios rurales hasta el instituto o centro de FP

más próximo.